





# **Final Project**

PBI Data Scientist VIX with ID/X Partners

Presented by Revito Pradipa



#### **Revito Pradipa**

https://linkedin.com/in/revitopradipa

#### **About You**

Undergraduate Informatics Engineering Student that always passionate to learn especially on Data and Machine Learning

#### **Insert Your Experience**

Head of AI Development GDSC UMS

Head of Legislation and Advocacy DPM FKI UMS

BDT 2022 - Data Analytics Program



#### **Business Understanding**

Sebuah perusahaan penyedia jasa kredit sering dihadapkan dengan masalah terkait risiko kredit. Risiko kredit adalah suatu risiko kerugian yang disebabkan oleh ketidakmampuan dari debitur atas kewajiban pembayaran utangnya baik utang pokok maupun bunganya ataupun keduanya.

Untuk mengurangi kerugian yang ada, perusahaan dapat membuat tindakan pencegahan dimana digunakan supaya dapat mengambil tindakan berdasarkan kemungkinan adanya risiko kredit



#### **Analytical approach**

Sebagai seorang Data Scientist, terdapat berbagai cara untuk menanggulangi masalah tersebut. Salah satu caranya dengan membuat model prediktif yang digunakan untuk mendeteksi kemungkinan debitur yang akan mengalami kesulitan dalam pembayaran kredit atau hutang.

Solusi yang sesuai adalah membuat model klasifikasi yang dapat mengklasifikasikan debitur yang terindikasi akan mengalami kesulitan pembayaran dan debitur yang dapat membayar secara lancar, dengan menggunakan data debitur yang telah ada sebelumnya.

# **Import**





Tahap pertama yaitu mengimpor beberapa library Data Analysis

## **Read CSV File**



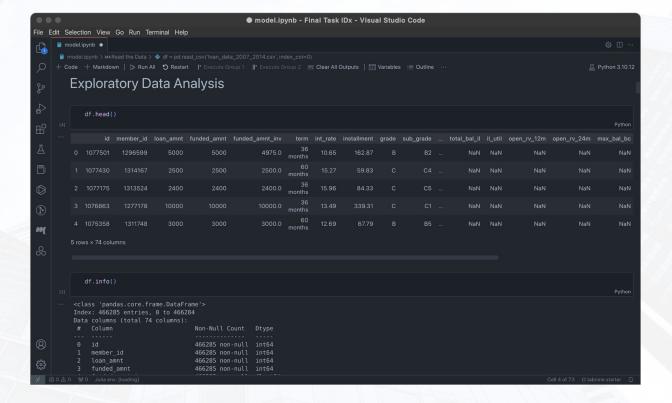
```
df = pd.read_csv('loan_data_2007_2014.csv', index_col=0)
df.shape
4
```

Kemudian dilanjut dengan membaca file dataset yang ada





Lalu melakukan Exploratory Data Analysis



## **Data Preprocessing**



```
"""### Delete columns in high missing data columns"""
   nan df percent[nan df percent > 40]
    df.drop(nan df percent[nan df percent > 40].index, axis=1, inplace=True)
   nan df percent = df.isnull().sum() / df.shape[0] * 100
    """### Delete rows in small missing data columns"""
   nan df small percent = nan df percent[(nan df percent > 0) & (nan df percent < 1)].sort values(ascending=False)
   def del missing row(df, list col):
        nan df percent = df.isnull().sum() / df.shape[0] * 100
        nan df percent = nan df percent[nan df percent > 0]
        return nan df percent
   """### Impute data with mean or mode for the rest of missing data columns"""
   nan df percent = del missing row(df, nan df small percent)
   nan df percent
   df[nan df percent.index].info()
   df[nan df percent.index].describe()
   def impute missing(df, cat col, num col):
        for col in num col.index:
        nan df percent = df.isnull().sum() / df.shape[0] * 100
        nan df percent = nan df percent[nan df percent > 0]
        return nan df percent
```

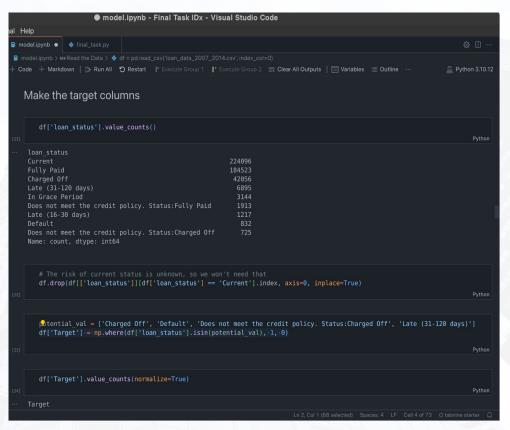
Pada tahap EDA, dilakukan pula data preprocessing seperti membersihkan data dan juga menghapus data duplikat

Pada tahap cleaning, dilakukan 3 cara yaitu menghapus kolom, baris, dan juga mengisi nilai kosong dengan teknik tertentu.

# **Target Variable**

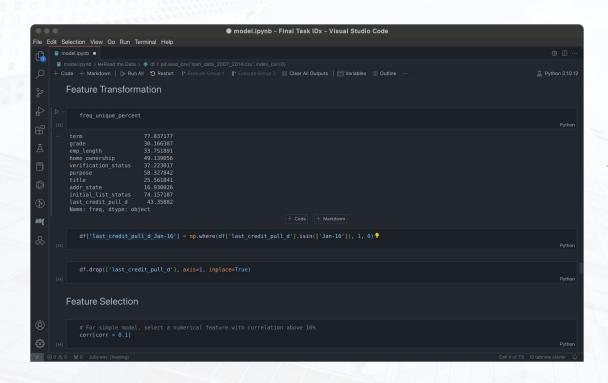


Kemudian membuat variabel dependent, yang menjadi indikator yang akan diprediksi kedepannya.



# **Feature Engineering**





Kemudian melakukan feature engineering yang berupa transformasi fitur dan pemilihan fitur

# Model Building & Tuning



Membuat model sekaligus mencari parameter terbaik menggunakan Grid Search

```
from sklearn.model selection import train test split, GridSearchCV
    X temp, X test, y temp, y test = train test split(X, y, test size=0.30, random state=101)
    X train, X val, y train, y val = train test split(X temp, y temp, test size=0.30, random state=101)
    cv params = {'n estimators' : [50,100],
                  'max depth' : [10,50],
                  'min samples leaf' : [0.5,1],
                  'min samples split' : [0.001, 0.01],
                  'max features' : ["sqrt"],
                  'max samples' : [.5,.9]}
   from sklearn.ensemble import RandomForestClassifier
    rfc = RandomForestClassifier(random state=101)
   rfc val = GridSearchCV(rfc, cv params, cv=5, refit='f1', n jobs = -1, verbose = 1)
   rfc val.fit(X train, y train)
   rfc val.best params
   y vpred = rfc val.predict(X val)
```

#### **Final Model**

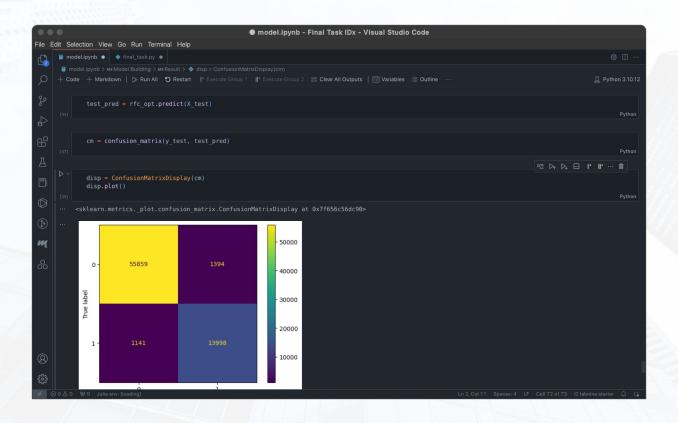


```
from sklearn.metrics import confusion matrix, classification report, ConfusionMatrixDisplay
    confusion matrix(y val, y vpred)
    disp = ConfusionMatrixDisplay(confusion matrix(y val, y vpred))
    disp.plot()
    print(classification report(y val, y vpred))
    """### Final Model"""
    rfc opt = RandomForestClassifier(n estimators = 100, max depth = 50,
                                   min samples leaf = 1, min samples split = 0.001,
                                   max features="sqrt", max samples = 0.9, random state = 101)
   rfc opt.fit(X temp, y temp)
```

Finalisasi model sesuai parameter terbaik yang telah dicari menggunakan Grid search

## Result





## **Model Performance**



print(	<pre>print(classification_report(y_test, test_pred))</pre>				
62]					
		precision	recall	f1-score	support
	0	0.98	0.98	0.98	57253
	1	0.91	0.92	0.92	15139
accura	асу			0.96	72392
macro a	avg	0.94	0.95	0.95	72392
weighted a	avg	0.97	0.96	0.97	72392

Performa akhir model cukup baik, dengan metrics f1-score 92% dan juga recall 91%



# **Github**

https://github.com/revitotan/idx-partners

# **Thank You**





